王志华 Carey

15885844762 · wzh2657751462@gmail.com
个人主页：https://kirito14it.github.io/ · GitHub 主页：https://github.com/Kirito14IT

2004.05 | 2023 级 | 仓库 star 总数约 2.5k | ACM 集训队员（银奖）

教育经历

复旦大学 复旦计算与智能创新学院 电子信息-计算机（**直硕**） 2027.09–2030.07

课题组：FVL、TEAI（负责人：**姜育刚副校长**） 导师：**马兴军** 2026.03–至今

上海理工大学（本科生） 光电信息与计算机工程学院 **计算机科学与技术（光电学院·院士创新班）** 2023.09–2027.07

研究兴趣：LLM Coding agent Agentic Training TrustWorthy AI
英语水平 CET-6/CET-4：516/522 **GPA：**3.9/4.5 **加权平均分：**90.51 **排名：**3/85

科研经历

MemHarmBench：面向持久记忆投毒的跨会话 LLM Agent 安全基准 2026.07–2026.10

复旦大学计算与智能创新学院**姜育刚** & **马兴军**导师访问学生
上海创智学院推荐论文 | 奇绩创坛 Alpha Sight 推荐论文 | **WWW 2027 在投** | **第一作者**

- **研究背景：** 长期记忆使智能体能够跨会话复用知识与规则，却也允许低权限协作者或外部内容植入持久恶意约束，并在后续无攻击载荷的任务中触发；现有单轮提示注入评测难以刻画此类风险。
- **主要内容：** 构建 MemHarmBench，覆盖用户、工作区所有者和外部利益相关者，含 12 类目标、24 种投毒模板和 12 个业务场景，共 288 个案例；设计“暴露–触发”协议，以 PMIR/C-ASR/UTDR/ATAR 评估记忆植入、攻击成功、任务偏移与轨迹异常。
- **主要职责：** 主导威胁模型与基准协议设计，构造直接/间接记忆投毒机制、跨业务场景任务及多维评测指标；提出跨会话对照实验与证据驱动的语义评测方法，负责实验设计、结果分析及论文写作。
- **核心成果：** 在真实智能体实验中观察到“隐蔽寄生”模式：恶意规则可跨会话影响后续决策，同时保持交付物完整与执行轨迹正常；表明持久记忆投毒可能隐藏于表面正常的任务执行过程，为智能体记忆安全提供新的评测视角。

ScamWeb：面向网络诈骗网页检测、细分类与证据定位的多模态基准 2026.04–2026.08

复旦大学可信具身智能研究院**马兴军** & **姜育刚**老师实习学生 | 公安部第三研究所 | AAAI 2027（accept*4） | **第一作者**

- **研究背景：** 现有数据集多聚焦钓鱼二分类与品牌冒充，缺少覆盖多类、多语言网络诈骗以及证据定位、可溯源解释的统一多模态基准。
- **主要内容：** 构建含 10,026 个网页、25 类诈骗和 47 种语言的 ScamWeb；其中 3,416 个诈骗页含 5,489 个专家证据框及解释。提出免训练 ScamDet，融合 URL、文本、视觉与 MHTML，级联完成检测、细分类、证据定位和解释生成。
- **主要职责：** 整合合作者采集的数据并完成清洗；设计无需训练的 ScamDet，从 URL、文本、视觉与 MHTML 中提取核心证据、过滤冗余信息，统一驱动二分类、细分类、区域定位与原因解释；负责实验设计、全量评测、结果分析及论文写作。
- **核心成果：** ScamDet 在零样本评测中取得 97.3% 召回率、63.9% 细分类准确率、0.193 mIoU 与 9.9 F1@0.5；尽管二分类性能仍低于传统专用模型，但无需按任务训练即可统一支持检测、细分类、定位与解释。

XSafeClaw：Agent 运行时安全治理的可信防护框架 Stars 165 获「机器之心」报道 2026.03–2026.06

复旦大学可信具身智能研究院 | 导师**马兴军** | 登上可信具身智能研究院首页“最新研究” | **核心贡献者**

- **研究定位：** 面向具备代码执行、工具调用与本地资产访问能力的智能体，构建跨运行时的“可观测–可拦截–可审批–可审计”安全闭环；统一支持 OpenClaw、Hermes 与 nanobot，开源获得 160+ GitHub Stars。
- **防护机制：** 以 AgentDoG 对完整会话轨迹开展多轮风险评估，并在工具调用前逐次拦截；高风险操作进入人工审批队列，同时联动文件、技能与记忆资产扫描。
- **核心贡献：** 主导 nanobot 端到端接入，完成 Runtime Registry/Gateway、Guard Hook、安装配置与自动启动、Safe Chat 及 Agent Valley 会话展示，统一异构运行时的会话身份与工具事件。
- **工程落地：** 实现并发多会话通信及三类运行时按模型 Token/成本核算，完善运行时防护与集成测试，并参与后续版本的开发与维护。

论文与知识产权

- **ScamWeb**：**AAAI 2027（CCF-A）**第一作者和博士后合作在投。
- **HorizonGuard**：**AAAI 2027（CCF-A）**本科生第一作者在投；**马兴军**老师指导，2 位博士共同一作。
- **MemHarmBench**：投稿于 **WWW 2027** 第一作者，面向智能体持久记忆投毒安全评测。
- **SFMambaNet**：第一作者，arXiv:2606.04493，**IEEE TIP（SCI 一区/CCF-A）**在投。
- **SafeCodeRL**：第一作者，发表（**CCF-C**）。
- **软件著作权**：《DL 驱动的鲁棒型数字水印网络应用》《基于 CodeQL 与 LLM 的代码安全分析系统》**第一作者**
- 公安部第三研究所网安中心**相关专利**申请正在评审。

竞赛与奖学金

2025 ACM 上海赛区大学生程序设计竞赛 **银奖** 2025.07
2025 年第十六届蓝桥杯全国软件和信息技术专业人才大赛全国总决赛 C/C++ **国家级二等奖** 2025.06
2025 年睿抗机器人开发者大赛编程赛道全国总决赛 **国家级一等奖** 2025.08
全国计算机能力挑战赛编程赛 c/c++ **国家级二等奖 *2** 2025.11
第九届全国大学生嵌入式芯片与系统设计竞赛全国总决赛 **国家级一等奖** 2024.11–2026.08

- 国家励志奖学金 *5、学习优秀奖学金 *1、学习优秀奖学金二等奖 *3、学习优秀奖学金三等奖 *2、优秀学生奖学金专项奖等。

实习经历

信息网络安全公安部重点实验室（公安部第三研究所上海） AI 研究实习生 2026.04–至今
国际组织（联合国志愿人员组织）–UNDP，研究实习生（线上） 2026.01–2026.04

技能与服务

工具类： LaTeX 科研写作；PyTorch/TensorFlow；Transformer/CNN。
智能体工具： Codex、Claude Code、DeepSeek-Harness；代码实现、实验自动化与调试验证。
编程类： C/C++、Python、Java；高性能算法开发与 Agent harness 工程。
语言类： 英语四、六级；可独立阅读英文文献。 **NeurIPS2026 审稿人**